

Automatización de la Revisión Bibliográfica en Bibliotecas Universitarias: De la Solución Híbrida al Futuro Escalable vía APIs

Resumen

La gestión y revisión bibliográfica es un componente estratégico en la administración de colecciones en bibliotecas universitarias, especialmente en contextos de acreditación, renovación curricular y toma de decisiones basadas en evidencia. Este artículo describe el desarrollo e implementación de un sistema automatizado, híbrido, para la revisión y cotejo de referencias en formato APA 7, analiza sus ventajas y limitaciones, y propone una hoja de ruta para su evolución hacia soluciones más escalables mediante integración de APIs. Se discute la relevancia de la automatización y la inteligencia artificial en la bibliotecología contemporánea, así como el valor de la revisión bibliográfica como herramienta de diagnóstico y mejora de la colección.

Introducción

La revisión bibliográfica, tradicionalmente un proceso manual y propenso a errores, es fundamental para el aseguramiento de la calidad en bibliotecas universitarias. En el contexto actual, la presión por cumplir con normativas de acreditación y la demanda de servicios ágiles por parte de las comunidades académicas, exigen avanzar hacia sistemas automatizados que permitan analizar, cotejar y validar grandes volúmenes de referencias en poco tiempo y con alta confiabilidad.

El desafío de las referencias en formato APA 7

Aunque la norma APA 7 proporciona una estructura estándar para la citación, la realidad en la elaboración de referencias es mucho más caótica: múltiples autores, anotaciones en el año (ej. "trad. 2004"), títulos en diversos idiomas y con signos especiales, variaciones en el orden de ciudad/editorial, y presencia de recursos digitales y artículos científicos con identificadores (DOI, URL). Esta diversidad representa un reto significativo para cualquier sistema de automatización que pretenda extraer información relevante y cotejarla eficientemente con el catálogo local o recursos externos.

```
# Ejemplo: Función de cotejo flexible de libros (con normalización y fuzzy matching)
def cotejar_libro(ref, df_catálogo):
    autor_ref, ano_ref, titulo_ref = extraer_datos_apa(ref)
    if not all([autor_ref, ano_ref, titulo_ref]):
        return {"Encontrado": False, "Observaciones": "APA incompleta"}
    # Normaliza autor y título
    aut_ref_norm = normalizar_texto(autor_ref.split()[0])
    tit_ref_norm = normalizar_texto(titulo_ref)
    df_cat = df_catálogo.copy()
    df_cat["autor_norm"] = df_cat["autor"].apply(normalizar_texto)
    df_cat["titulo_norm"] = df_cat["titulo"].apply(normalizar_texto)
    # Calcula similitud de título
    df_cat["sim_titulo"] = df_cat["titulo_norm"].apply(lambda x: fuzz.token_set_ratio(x, tit_ref_norm))
    df_match = df_cat[(df_cat["ano"] >= ano_ref) &
                      (df_cat["autor_norm"].str.contains(aut_ref_norm)) &
                      (df_cat["sim_titulo"] >= 80)]
    if not df_match.empty:
        fila = df_match.iloc[0]
        return {"Encontrado": True, "Ejemplares": int(fila["numero_ejemplares"]), "Año": fila["ano"],
                "Observaciones": f"{fila['numero_ejemplares']} ejemplares ({fila['ano']})"}
    return {"Encontrado": False, "Observaciones": "No encontrado"}
```

Esta función automatiza el cotejo entre una referencia APA y el catálogo, usando técnicas de normalización y similitud para máxima precisión.

Solución híbrida desarrollada

Al ejecutar el script ``procesar_referencias_apa7_mejorado_final.py``, el sistema realiza automáticamente las siguientes etapas:



Nota: En el caso de los artículos de revista, debido a las restricciones técnicas de acceso a ciertos recursos y bases de datos, el sistema actualmente incorpora en la salida el enlace directo a la búsqueda del artículo en Google, facilitando su posterior verificación manual por parte del usuario.

A continuación se muestra la consola de Windows mientras el script está en funcionamiento, procesando referencias de manera automática:



```

Microsoft Windows [Versión 10.0.26100.4061]
(c) Microsoft Corporation. Todos los derechos reservados.

C:\Users\pcoca>cd..

C:\Users>cd..

C:\>cd CotejoAutomatizado

C:\CotejoAutomatizado>python procesar_referencias_apa7_mejorado_final.py
✓ ChromeDriver iniciado automáticamente.

DevTools listening on ws://127.0.0.1:51401/devtools/browser/775ec8ca-326b-4aa4-84ec-2990c52bb3d7
Procesando referencias: 1%| | 2/295 [00:01<03:54, 1.25it/s]C
reated TensorFlow Lite XNNPACK delegate for CPU.
Procesando referencias: 1%| | 4/295 [00:31<49:36, 10.23s/it]A
ttempting to use a delegate that only supports static-sized tensors with a graph that has dynamic-sized tensors (tensor#
58 is a dynamic-sized tensor).
Procesando referencias: 34%| | 100/295 [22:08<42:07, 12.96s/it]

```

Flujo de trabajo del script de automatización


Se diseñó un sistema basado en Python, estructurado en módulos, que integra: carga y normalización robusta de planillas de referencias y catálogo; extracción ultraflexible de campos bibliográficos usando expresiones regulares avanzadas y heurísticas tolerantes a variantes; clasificación automática del tipo de recurso (libro, artículo, capítulo, tesis, etc.); cotejo automatizado con el catálogo local empleando técnicas de fuzzy matching para maximizar coincidencias incluso con títulos y autores parcialmente coincidentes; búsqueda y verificación externa mediante web scraping en Buscalibre y Google, usando Selenium, para obtener precios y detectar acceso a artículos de revista; generación de reportes consolidados en CSV/Excel con resultados trazables y observaciones para revisión profesional. El flujo se diseñó para ser escalable y modular, permitiendo futuras integraciones y mejoras sin alterar la lógica principal.

Limitaciones del enfoque actual

El principal cuello de botella es la dependencia del web scraping (Selenium/ChromeDriver) para búsqueda en Google y sitios de librerías, lo cual implica vulnerabilidad a cambios de interfaz y bloqueos (CAPTCHA, limitaciones de IP); dependencia de infraestructura local (requiere ChromeDriver actualizado, compatibilidad con el sistema operativo); imposibilidad de procesamiento a gran escala o en la nube sin incurrir en riesgos de bloqueo; y complejidad para la integración institucional y replicabilidad en otras bibliotecas.

Alternativas y hoja de ruta para la escalabilidad

Para superar estas limitaciones, se propone migrar hacia un enfoque basado en APIs abiertas y servicios de consulta estructurada: CrossRef (para artículos científicos y DOIs), OpenAlex o Scopus (para análisis bibliométrico avanzado), DOAJ (para revistas de acceso abierto), Google Books e ISBNdb (para libros impresos y digitales), WorldCat (para disponibilidad global), e integración con sistemas de gestión bibliotecaria vía MARC21, Koha API, u otros. La arquitectura futura prioriza la interoperabilidad, la trazabilidad y la capacidad de integrarse en sistemas de análisis institucional o dashboards de gestión (ver Figura 1).


Figura 1. Arquitectura futura escalable con APIs y revisión human-in-the-loop.

El valor estratégico: IA, automatización y el rol humano en la gestión bibliotecaria

La irrupción de la inteligencia artificial (IA) en la bibliotecología universitaria representa una oportunidad inédita para transformar procesos rutinarios en flujos inteligentes, capaces de adaptarse y aprender de la diversidad y variabilidad de las referencias reales. Herramientas de IA, como los modelos de lenguaje natural (LLM), algoritmos de aprendizaje automático y sistemas de reconocimiento de patrones, permiten automatizar la normalización, clasificación y cotejo de referencias con una velocidad y precisión impensadas hace solo una década. Sin embargo, el futuro de la gestión bibliotecaria no es exclusivamente automatizado. La experiencia profesional del bibliotecólogo, su conocimiento contextual y su capacidad de discernimiento siguen siendo fundamentales para detectar casos excepcionales o ambiguos no resueltos por la IA, tomar decisiones informadas ante variantes culturales, lingüísticas o disciplinarias en las referencias, definir criterios de calidad y pertinencia para la colección y retroalimentar los sistemas automáticos con ejemplos y correcciones, potenciando el aprendizaje continuo y la mejora de los modelos. El enfoque más prometedor es, por tanto, la simbiosis entre IA y razonamiento humano: sistemas automáticos que procesan el 80-90% de los casos rutinarios y destacan los casos “dudosos” o fuera de norma para revisión y validación humana.

Ejemplo de código para cotejo automático de libros:

La interacción entre sistemas automáticos y profesionales humanos es el corazón del avance en bibliotecas universitarias modernas. Mientras la IA procesa grandes volúmenes y automatiza el 80-90% de los casos, la revisión y el criterio del bibliotecólogo aseguran la calidad final y la mejora continua del sistema. Esta sinergia permite una gestión más ágil, confiable y adaptativa ante la diversidad real de las referencias (ver Figura 2).

Figura 2. Flujo general del sistema híbrido (automatización + revisión humana).

Conclusiones

La automatización de la revisión bibliográfica, aunque enfrenta retos técnicos y metodológicos, representa un paso necesario para la modernización y profesionalización de la gestión bibliotecaria. El paso desde soluciones híbridas basadas en scraping hacia arquitecturas escalables vía APIs es esencial para la sostenibilidad y la integración institucional a futuro. El rol de la inteligencia artificial y la automatización será cada vez más relevante en el diagnóstico, gestión y proyección estratégica de las bibliotecas universitarias (Ver Figura 3).

Para avanzar hacia la consolidación y escalabilidad de este proyecto, resulta imprescindible contar con el apoyo técnico del área de informática institucional. Esta colaboración permitiría implementar la solución accediendo directamente a la base de datos del catálogo mediante una API, lo que no solo optimizaría la automatización y la integración del sistema, sino que también facilitaría la adaptación de la herramienta a las necesidades específicas de la biblioteca. De este modo, se aseguraría la sostenibilidad, eficiencia y capacidad de evolución del proyecto en el mediano y largo plazo.

Figura 3. Ventajas estratégicas: comparación entre automatización, revisión humana y enfoque híbrido.



Anexo 1. Prompt inicial para el desarrollo del sistema automatizado

Eres un experto programador de Python y creador de script, además de ser un bibliotecólogo por más de 20 años, en base al archivo que cargue necesito poder hacer el llenado de esa planilla de forma automática cotejando por un lado las referencias que están en formato APA 7 y son de diferente naturaleza, materias e idiomas, con una planilla que contine todos los títulos y sus respectivos ejemplares que tiene la biblioteca, me debes indicar que tipo de archivo es más efectivo para poder realizar la tarea, csv, tsv, crear un script que pueda hacer el cotejo y llenado de la planilla de forma de automatizar la tarea de revisión bibliográfica en el catálogo de biblioteca en línea, este script deberá ser lo suficientemente robusto para funcionar con todas las colecciones de las distintas bibliotecas, y además ser muy preciso y exacto en la búsqueda y recuperación de la información. Las referencias contienen en la misma celda según el tipo de recursos, artículos científicos, autor, año, título. Título de la revista, volumen, número y páginas, capítulos de libros contine, autor, año, título del capítulo, dice EN autores, título del libro, editorial y si está disponible en línea la URL, libros contiene, autor, año, título del libro, editorial, a continuación ejemplos de referencias para que las puedas identificar, subiré además la norma APA 7 en inglés para que aprendas a identificar y poder extraer la información. La estructura de la planilla de referencias es la siguiente y contiene columnas vacías que son las que se deberían llenar Columna A: Referencia Columna B: En la Unidad académica Columna C: En otras Bibliotecas Columna D: Disponible on line URL Columna E: Artículo Científico Columna F: Observaciones Columna G: Año Columna H: Proveedor Columna I: Valor pesos Estas columnas vacías están porque de no estar el recurso en el catálogo se deberá cotizar en internet y colocar el proveedor y el valor en pesos chilenos, como proveedor se deben seleccionar entre Amazon, Buscalibe, Iberlibro o Abebooks. Referencia libros Herrera Cáceres, C. y Rosillo Peña, M. (2019). Confort y eficiencia energética en el diseño de edificaciones. Universidad del Valle. Artículo revista Castañeda Naranjo, L. A. y Palacios Neri, J. (2015). Nanotecnología: fuente de nuevos paradigmas. Mundo Nano. Revista Interdisciplinaria en Nanociencias y Nanotecnología, 7(12), 45-49. <https://doi.org/10.22201/ceiich.24485691e.2014.12.49710> Artículo en un periódico Carreño, L. (9 de febrero de 2020). La disputa gremial por los aranceles a las prendas de vestir. El Espectador. <https://www.elespectador.com/economia/la-disputagremial-por-los-aranceles-las-prendas-de-vestir-articulo-903768> Capítulo de un libro con editor Apellido Autor, N. N. (año). Título del capítulo o entrada en N. Apellido Editor (Ed.), Título del libro (xx ed., Vol. xx, pp. xxx-xxx). Editorial. La planilla donde se encuentra la colección de donde el código deberá ser capaz de extraer la cantidad de ejemplares que hay en la biblioteca tiene el siguiente formato Columna A: número de ejemplares Columna B: título Columna C: autor Columna D: Año Algunas consideraciones: El año de la referencia deberá encontrar en la planilla de la colección un año igual o mayor, en caso de existir los dos se deberá indicar como aparece en el ejemplo Como encargado del proyecto deberás guiarme en todo el proceso de automatización de esta tarea, y deberás crear un código que me permita llenar la planilla, puede que los archivos los tengas que normalizar para evitar errores de tabulaciones, comas, o comillas, esto es muy importante para asegurar el éxito del cruce y recuperación de la información solicitada, esto debería estar incluido como el primer paso del código, que verifique que los archivos están debidamente normalizados y preparados para realizar el cruce.

Prompt original que definió el flujo y requisitos del proyecto.